Український Католицький Університет

Курс «Штучний інтелект» · Семестровий проєкт · 2026

Cleany: автоматичне сортування сміття роботом-маніпулятором SO-101

Візуомоторна (visuo-proprioceptive) політика для сортування побутових відходів маніпулятором LeRobot SO-101

Команда:

Пасічник Назар

Бугір Єлизавета

Ментор:

Катерина Зоріна

Репозиторій:

https://github.com/dark-neonus/Cleany_AI_Trash_Sorting_Robot.git

Пропозиція проєкту, подана в межах курсу «Штучний інтелект»

Факультет прикладних наук

2026-09-20

1. Проблема та мотивація

Ручне сортування побутових відходів повільне й схильне до помилок, що знижує чистоту вторинної сировини. Ми будуємо прототип: маніпулятор SO-101 (LeRobot) бере предмет з робочої зони й кладе його у відповідний отвір коробки-сортувальника (папір/скло/пластик/метал/інше, під кожним отвором – сміттєвий пакет). Коробка має вбудовану камеру з власною підсвіткою для стабільного освітлення незалежно від зовнішніх умов. Замість пайплайна ”детектор + керування за координатами” ми навчаємо **візуомоторну (visuo-proprioceptive) політику**: end-to-end модель, яка приймає кадри камери *й* стан суглобів маніпулятора (пропріоцепцію) і напряму видає моторні команди, без будь-якого текстового промпта чи мовної інструкції – тобто це не VLA, а класична політика імітаційного навчання (imitation learning).

2. Огляд джерел та наявних рішень

Класичні системи сортування поєднують YOLO-детектор із маніпулятором, керованим за фіксованими координатами. Prakash et al. [1] досягли точності сортування ∼81.8% (YOLOv8 + SCORBOT-ER 4u), відзначаючи чутливість до освітлення й брак зворотного зв’язку про захоплення – звідси наше рішення про закриту коробку зі стабільною підсвіткою. Paudel et al. [2] (YOLOv8 + дельта-робот, mAP ≈96%) та Hossain et al. [3] (CNN-класифікатор, $>92\%$) підтверджують ефективність такого модульного пайплайна, а Bacchin et al. [4] описують загальний перехід галузі до YOLO/Faster R-CNN. Такі модульні пайплайни легше налагоджувати й вимагають менше даних, але гірше справляються з деформованими, м’якими чи нестандартними предметами (зім’ятий папір, розчавлені банки) – саме тому ми обираємо end-to-end підхід.

Для навчання самої політики ми спираємось на двох сучасних архітектурах end-to-end імітаційного навчання. ACT (Action Chunking Transformer) [5] передбачає короткі ”чанки” майбутніх дій наперед, що компенсує затримки й шум телеоперації та дає плавний рух; саме цю модель навчають в офіційному туторіалі LeRobot з імітаційного навчання на реальних роботах [6], тому вона є нашою легкою відправною точкою. Diffusion Policy [7] генерує дії через дифузійний процес, що краще передає багатомодальні розподіли рухів (коли для одного стану існує кілька валідних дій) і дає плавніші траєкторії, ціною складнішого й повільнішого навчання/інференсу. Свіжий бенчмарк політик на реальному SO-101 [8] (серед них — і ACT) показує, що типовий масштаб даних для однієї задачі — порядку 100 демонстрацій телеоперації, а основним джерелом невдач є не помилки розпізнавання, а нестабільність фізичного виконання руху; цю декомпозицію невдач ми частково переймаємо (§5). Відома проблема таких політик – ”проприоцептивне оверфітування” (proprioception overfitting): маючи доступ і до зображення, і до стану суглобів, мережа може навчитись ”підглядати” в моторні дані та відтворювати запам’ятовану траєкторію замість того, щоб справді реагувати на візуальні ознаки предмета, що шкодить узагальненню при зміні положення об’єкта – цей ризик ми враховуємо в плані оцінювання й донавчання.

3. Дані

Основний фокус – власні демонстрації телеоперації SO-101 у коробці з підсвіткою й п’ятьма промаркованими отворами (папір/скло/пластик/метал/інше): мінімум ∼50–100 епізодів на клас через стандартний LeRobot data-pipeline (кадр камери – стан суглобів – дія), з варіюванням положення предмета в кадрі, щоб зменшити ризик проприоцептивного оверфітування. Додатково плануємо використати публічні датасети як допоміжне джерело: Kaggle ”Garbage Classification” [9] – для оцінки візуальної різноманітності об’єктів кожного класу та як матеріал для класичного baseline-пайплайна.

4. Підхід і методи

1. **Пілотне навчання (перевірка пайплайну):** донавчання легшої ACT-моделі на невеликому наборі демонстрацій для одного класу/предмета (ще без фінальної коробки) – перевірка, чи вистачає обчислювальних ресурсів і часу на повний цикл ”телеоперація → навчання → інференс на SO-101”.
2. **Вибір архітектури:** за результатами пілота – компактніша ACT (швидше навчання/інференс) чи Diffusion Policy [7] (краще для деформованих/м’яких предметів, ціною складнішого навчання); паралельно добудова коробки й розширення збору демонстрацій на всі п’ять класів.
3. **Навчання й інтеграція:** навчання обраної політики на повному датасеті за пайплайном LeRobot [6]; інференс у реальному часі: кадр камери + стан суглобів → чанк дій → виконання на SO-101 → повернення в домашню позицію.

5. Оцінювання результатів

- **Task success rate** по кожному з п’яти класів (захоплено *і* покладено правильно).
- **Grasp success rate** окремо від **placement accuracy** (матриця ”клас × обраний отвір”).
- **Декомпозиція відмов** (помилка вибору отвору vs. помилка фізичного виконання руху) за аналогією з [8].
- **Перевірка на пропріоцептивне оверфітування:** успішність при зміщеному/незвичному положенні предмета в коробці відносно тренувальних демонстрацій.
- **Latency** інференсу та **узагальнення** на нових екземплярах класу.
- **Baseline:** класичний пайплайн ”детектор + координати” та орієнтир ∼81.8% [1].

6. План і ризики

Перші тижні: пілотне навчання ACT на одному класі/предметі для перевірки повного пайплайну й обчислювального бюджету.

До midterm: вибір архітектури (ACT чи Diffusion Policy), побудова коробки, збір датасету для 1–2 класів, перший повний прогін навчання.

До захисту (іспиту): 3–5 класів, повна інтеграція, метрики на серії прогонів, порівняння з baseline.

Ключові ризики:

- *Брак compute/даних для навчання політики з нуля* → легша архітектура (ACT замість Diffusion Policy), менше класів/епізодів, хмарні ресурси, відкат до класичного пайплайна.
- *Пропріоцептивне оверфітування* (політика ”підглядає” в стан суглобів замість зображення) → варіювання положення предметів у демонстраціях, окрема перевірка узагальнення (§5).
- *Нестабільне захоплення* (слизькі/скляні об’єкти) → простіші предмети, калібрування сили захвату.
- *Затримки інференсу* → легша модель, менша роздільність, коротший action chunk.
- *Брак часу на всі класи* → 3 найпростіші класи + фіксовані координати для решти.

7. Contribution statement

- **Пасічник Назар** — налаштування SO-101 (телеоперація, калібрування), виготовлення коробки-сортувальника, пілотне навчання й навчання фінальної політики
- **Бугір Єлизавета** — налаштування LeRobot-пайплайну, вибір і порівняння архітектур, метрики й евалюація, документація
- **Обидва учасники** — збір і розмітка датасету демонстрацій

Список джерел

[1] Upshanth Prakash, Trishaal Datt, Amitesh Prasad, Waisake Saraqia, and Utkal Mehta. Real-time solid waste sorting using a vision-enabled robotic platform. *Waste*, 4(2):16, 2026. doi:10.3390/waste4020016.

[2] P. Paudel, S. Shrestha, S. Shrestha, S. Gurung, and S. Adhikari. Automated waste sorting with delta arm and yolov8 detection. *Journal of Artificial Intelligence and Capsule Networks*, 6:299–315, 2024. doi:10.36548/jaicn.2024.3.004.

[3] M. S. Hossain, M. M. Hasan, R. Rahman, M. R. Islam, and M. M. Hossain. Multi-class waste segregation using computer vision and robotic arm. *PeerJ Computer Science*, 10:e1957, 2024. doi:10.7717/peerj-cs.1957.

[4] A. Bacchin, N. Carlon, S. Tonello, A. Pretto, and E. Menegatti. Ai and robotics for waste sorting and recycling. In *Proceedings of the International Workshop on AI and Robotics for Waste Sorting*, Pisa, Italy, 2023. CEUR Workshop Proceedings, available online: https://ceur-ws.org/Vol-3486/170.pdf (accessed 20 November 2025).

[5] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware, 2023. Proceedings of Robotics: Science and Systems (RSS), arXiv:2304.13705.

[6] Hugging Face. Imitation learning on real-world robots (lerobot documentation), 2026. online: https://huggingface.co/docs/lerobot/il_robots.

[7] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion, 2023. Proceedings of Robotics: Science and Systems (RSS), arXiv:2303.04137.

[8] Benchmarking vision-language-action models on so-101: Failure and recovery analysis, 2026. arXiv preprint arXiv:2606.08881.

[9] Mostafa Abla. Garbage classification dataset, 2020. Kaggle, online: https://www.kaggle.com/datasets/mostafaabla/garbage-classification.